

Содержание

Распознавание произнесённых чисел на русском — отчёт по стратегии	1
Задача и метрика	1
Ограничения задачи	1
Коротко	1
Анализ данных — отправная точка стратегии	2
Архитектура модели	3
Что сработало — таблица вкладов	3
Что сработало — детализация по порядку вклада	4
Что проверили и не взяли в финал	8
Что осознанно не делали	9
Ход сессий и принятые решения	9
Бюджет вычислений	10
Связь валидационного CER и LB	10
Пример остаточной ошибки модели	11
Что можно попробовать дальше	11
Итоговый пайплайн инференса (Kaggle-кernels)	12
Структура проекта	12
История сабмитов	13
Главные уроки	13

Распознавание произнесённых чисел на русском — отчёт по стратегии

Соревнование: asr-2026-spoken-numbers-recognition-challenge.

Команда на Kaggle: Mamarin & Solomenchuk. Финальный результат на публичной части лидерборда: 0.946 CER, место #3. Выполнили: вредный Георгий Мамарин и обаятельная Оксана Соломенчук

Задача и метрика

На вход — аудиозапись, где человек называет число (русской речью). На выход — то же число в виде строки цифр. Диапазон значений в данных — от нескольких единиц до 999 999.

Основная метрика соревнования — Character Error Rate (CER), посимвольное редакционное расстояние между предсказанной строкой цифр и эталонной, нормированное на длину эталона. Ошибки считаются по цифровому представлению числа, а не по словесному.

При локальной валидации дополнительно использовалось гармоническое среднее CER по доменам (in-domain — говорящие, которые есть в обучении; OOD — новые):

$$\text{harmonic_cer} = 2 \cdot \text{CER_in} \cdot \text{CER_ood} / (\text{CER_in} + \text{CER_ood})$$

Гармоническое среднее сильно штрафует модели с дисбалансом между доменами: если один из CER растёт, `harmonic_cer` реагирует сильнее, чем обычное среднее. Поскольку Kaggle-метрика соревнования делает акцент на OOD-говорящих, именно `harmonic_cer` на валидации использовался как критерий выбора чекпоинтов.

Далее в отчёте «CER» без уточнения — это валидационный CER по всей выборке.

Ограничения задачи

- Обучение только на предоставленных данных, с нуля.
- Модель не более 5 млн параметров (у нас ~3.5 млн).
- Инференс — самодостаточный, 16 ГГц, без `torchaudio`.

Коротко

#	Этап	Ключевая идея	Валидационный CER	LB
0	Базовая модель (прошлая сессия)	Conv + BiGRU + CTC, слабые аугментации	0.0738	6.835
1	Набор аугментаций v2, +1 эпоха	mp3 / полоса / тон + балансировка говорящих + усиленный SpecAugment	0.0535	5.082
2	Дообучение до плато (эпоха 6)	тот же рецепт, убывающий LR	0.0455	4.440
3	SWA двух соседних эпох (8, 9)	первое полезное усреднение весов	0.0394	4.034
4	Обучение с нуля 20 эпох + SWA + ТТА	чистый старт со всеми аугментациями	0.0223	2.362
5	+ реверберация, дообучение 6 эпох + SWA + ТТА	последний акустический разрыв (эхо помещений)	0.0152	1.507
6	Ансамбль двух моделей (сиды 42 и 43) + ТТА + грамматический лучевой декодер	разнообразие инициализаций + усреднение логитов	0.0115	0.946

Снижение CER от базы этой сессии: -86 %.

Траектория LB:

Шаг:	0	1	2	3	4	5	6
CER:	6.835	5.082	4.440	4.034	2.362	1.507	0.946
		аугмент.	+2э.	SWA	с нуля	реверб	ансамбль

Анализ данных — отправная точка стратегии


Сравнение обучающей и валидационной выборок сразу подсказало направление работы.

Свойство	Обучение (12 553 записи)	Валидация (2 265 записей)
Расширение файла	только wav	wav 1 577 + mp3 688
Частота дискретизации	24 000 / 22 050 Гц	16 000 Гц (родная)
Число говорящих	6: Е 45 %, В 23 %, А/С/Д/Ф ≤ 10 %	10 (4 полностью новых: Н, І, J, К)
Длина аудио	~0.5–3 с	~0.5–3 с
Распределение меток	равномерно в [14; 999 888]	равномерно в [1 363; 999 669]

Главный вывод. Тестовая выборка, судя по валидации, содержит три расхождения с обучением: mp3-компрессию, родной 16 кГц звук и «новых» говорящих. Исходная гипотеза — основной выигрыш в закрытии этих расхождений через аугментации, а не через архитектуру. Впоследствии к списку добавилось четвёртое — эхо помещений; это не было видно из csv-метаданных и стало видно только после анализа остаточных ошибок на валидации.

Архитектура модели

Блок-диаграмма финальной модели (идентична для сидов 42 и 43):



Итого ~3.5 млн параметров.

Ключевые архитектурные решения:

- CTC на уровне слов, а не букв. Словарь из 42 слов + blank: «ноль», 9 мужских единиц «один...девять», 2 женских формы «одна, две» (остальные единицы совпадают с мужскими), 10 от «десяти» до «девятнадцати», 8 десятков, 9 сотен, 3 формы «тысяча/тысячи/тысяч». Любая валидная грамматическая последовательность слов детерминированно разбирается обратно в число.
- 2 свёрточных слоя со страйдом 2 + 3 BiGRU. Уменьшают временную размерность в 4 раза, что удобно для CTC и держит модель в бюджете 5 млн параметров.
- Log-mel 80 бинов, n_fft 400, hop 160 при 16 кГц. Самодостаточный фронтенд на soundfile + scipy. torchaudio в окружении был сломан, и пришлось обойтись без него — заодно сделало кернел инференса проще.
- AdamW, обрезание градиента нормой 5.0, косинусный график с прогревом.

Что сработало — таблица вкладов

Абляция каждого компонента на финальной конфигурации. «Вклад» — относительное снижение CER на валидации от отключения только этого компонента.

Компонент	CER без компонента	CER с компонентом	Относительное снижение
Обучение с нуля с полным набором аугментаций	0.0394 (лучший финал сессии 2)	0.0223	–43 %
Реверберация в аугментациях	0.0223	0.0152	–32 %
Ансамбль двух моделей (сиды 42 и 43)	0.0152 (сид 42 один, с ТТА)	0.0115 (ансамбль с ТТА)	–24 %
ТТА на инференсе	0.0166 (SWA реверба, жадный)	0.0152 (SWA реверба + ТТА)	–8 %

Компонент	CER без компонента	CER с компонентом	Относительное снижение
Усреднение весов соседних эпох (SWA)	0.0167 (одинокый лучший чекпоинт)	0.0166 (SWA, жадный)	-1 %
Грамматический лучевой декодер	0.0337 (жадный декодер, сессия 4)	0.0330 (лучевой, тот же чекпоинт)	-2 %

Главные «кирпичи» — обучение с нуля, реверберация и ансамбль. ТТА, SWA и лучевой декодер дают суммарно несколько процентов: поодиночке небольшой вклад, но все три совместимы и работают независимо.

Каскадное представление тех же цифр:




Рис. 1: Водопад главных вкладов

Что сработало — детализация по порядку вклада

1. Полное обучение с нуля со всеми аугментациями (4.034 → 2.362)

Главный перелом. Предыдущие итерации дообучали модель, которая в ранние эпохи никогда не видела mr3 , изменение тона или фильтрацию полосы. Веса энкодера были смещены и через дообучение плохо перестраивались. Обучение с нуля с полным набором аугментаций с первой эпохи изменило базовые представления энкодера.

Параметры обучения:

- 20 эпох, батч 16, оптимизатор AdamW, пиковый LR = $1e-3$.
- Косинусный график LR с прогревом 1.5 эпохи, минимум = 5 % от пика.
- Обрезание градиента нормой 5.0.
- Балансированный сэмплер говорящих (см. пункт 5).

Набор аугментаций (применяются независимо в каждом примере):

- Преобразование через mp3 (lameenc, 48/64/96/128 kbps, вероятность 0.35) — прямая симуляция кодека, встречающегося в валидации.
- Низкочастотный фильтр 3 500–7 500 Гц (вероятность 0.25) — имитация узкополосных микрофонов.
- Сдвиг тона ± 2.5 полутона (вероятность 0.3) — приближение «новых» голосов.
- Изменение темпа 0.9–1.1 $\times$ (вероятность 0.3).
- Изменение громкости ± 6 дБ (вероятность 0.5) и добавление шума std 0.001–0.01 (вероятность 0.3).
- Усиленный SpecAugment: временная маска до 25 кадров + относительная маска 8 % длины, частотная маска до 20 бинов.

Динамика валидационного CER по эпохам:

Эпоха	1	3	7	10	14	16	18	20
CER	0.851	0.059	0.034	0.033	0.027	0.025	0.026	0.025

График всех трёх обучающих циклов на одной оси:




Рис. 2: Кривые обучения

На графике видно главное наблюдение сессии 5: зелёная кривая (сид 43, реверб с 1-й эпохи) полностью обгоняет синюю (сид 42, реверб только с 21-й эпохи через дообучение) при равном вычислительном бюджете. Это прямое подтверждение тезиса «сильные аугментации, заложенные с самого начала обучения, работают лучше, чем добавленные поздно».

2. Реверберация (2.362 → 1.507)

Оставался один неучтённый акустический фактор: записи из валидации сделаны в реальных помещениях с лёгким эхом, а никакая наша аугментация этого не воспроизводила. Добавили реверберацию и сделали дообучение в 6 эпох с пиковым LR = $2e-4$ и тем же косинусным графиком.

Реализация (src/asr_numbers/augment.py):

- Импульсная характеристика: экспоненциально затухающий белый шум, время реверберации $rt60 \in [40, 250]$ мс.
- Степень «влажности» $wet_mix \in [0.15, 0.55]$, прямой путь сохраняется ($ir[0] = 1.0$).
- Нормализация среднеквадратичной амплитуды «влажного» сигнала, чтобы аугментация не «глушила» речь.

Динамика CER на валидации (начали с уровня 0.0223, пик — эпоха 26 через SWA):

Эпоха	21	22	23	24	25	26
CER	0.020	0.019	0.017	0.018	0.017	0.017

Эффект на самых тяжёлых говорящих валидации:

Говорящий	До реверба	После реверба	Изменение
spk_H (OOD)	0.0319	0.0184	−42 %
spk_K (OOD)	0.0357	0.0286	−20 %

Полная картина по всем говорящим и всем ключевым этапам:




Рис. 3: Эволюция CER по говорящим

Видно, что OOD-говорящие (H, I, J, K — справа от пунктира) в каждой итерации падают резче, чем in-domain. Особенно заметен вклад реверберации: для spk_H ошибка уменьшилась в 2.4 раза между синим и светло-синим баром. Ансамбль (зелёный) даёт последний равномерный тонкий проход по всем говорящим.

Финальная валидация: 0.0223 → 0.0167 (лучший одиночный чекпоинт) → 0.0166 (SWA) → 0.0152 вместе с TTA.

3. Ансамбль двух моделей с разными сидами (1.507 → 0.946)

Обучили независимую модель с сидом 43, с нуля на 22 эпохах, причём реверберация входила в аугментации уже с первой эпохи. Лучший одиночный чекпоинт сида 43 — эпоха 20, CER 0.0128 — заметно лучше финала сида 42 (0.0166). Это побочное подтверждение идеи, что реверберация с нуля работает сильнее, чем добавленная поздно.

Динамика обучения сида 43:

Эпоха	1	3	6	10	13	15	17	20	22
CER	0.825	0.050	0.028	0.023	0.018	0.015	0.015	0.013	0.014

Ансамбль на инференсе — усреднение log-softmax обеих моделей (каждая с TTA) в одном тензоре, затем грамматический лучевой декодер:

```

Модель-42 → TTA (4 прогона) → усреднение log_softmax_A
Модель-43 → TTA (4 прогона) → усреднение log_softmax_B
                        ↓
                    fused = (log_softmax_A + log_softmax_B) / 2
                        ↓
                    grammar_beam_decode(fused, beam = 16)

```

Эффект:

Вариант	Валидационный CER	spk_K (OOD)	LB
Одиночный лучший (сид 42, reverb + SWA + TTA)	0.0152	0.0286	1.507
Одиночный лучший (сид 43, эпоха 20, без TTA)	0.0128	0.0241	—
Ансамбль + TTA + лучевой декодер	0.0115	0.0223	0.946

4. Усиленный SpecAugment

Базовый SpecAugment использует фиксированные максимальные ширины масок. Добавили относительный параметр `time_mask_ratio = 0.08`: временная маска масштабируется с длиной клипа. Максимальная частотная маска — 20 бинов из 80 mel (25 % покрытия). Отдельного A/B не делали, но это часть пакета v2, давшего 0.0738 → 0.0535 за одну эпоху.

5. Балансировка говорящих в обучении

Обучающая выборка сильно перекошена: 68 % примеров — `spk_E` и `spk_B`. Энкодер «прилипал» к их формантам и проваливался на новых голосах. Применили `WeightedRandomSampler` с весом $1 / \sqrt{\text{count}(\text{spk})}$ — выравнивает вклад каждого говорящего в градиент. Часть пакета v2.

6. Грамматический CTC-лучевой декодер

Модель выдаёт слова («сто сорок три тысячи пятьсот»), а не цифры. Грамматика чисел от 0 до 999 999 — крошечный конечный автомат: триплет (сотни / десятки / единицы, с двумя регистрами для мужского и женского рода) → опциональный маркер «тысяч / тысячи / тысяча» → остаточный триплет.

Реализация (`src/asr_numbers/decoder.py`):

- Состояние автомата: (раздел, состояние_триплета, род, флаг_тысячи).
- Ключ в луче: (накопленные_токены, состояние_автомата).
- Используются стандартные правила лучевого поиска для CTC (алгоритм CTC prefix beam search): обработка пустого кадра, повторной метки и расширения префикса. Переходы по токенам разрешены только в соответствии с грамматикой.
- Размер луча не играет роли: $16 \equiv 32 \equiv 64$ — грамматика сама исчерпывает пространство гипотез.

Относительно жадного декодера выигрыш умеренный (порядка 1–3 %), но критичный для отдельных случаев: жадный декодер мог выдать «сто пятьсот двадцать четыре» (две сотни), а лучевой декодер такой путь отбрасывает как грамматически невалидный.

7. ТТА на инференсе: сдвиг тона ± 0.5 полутона + полоса 5.5 кГц

Три дополнительные версии аудио, усреднение log-softmax. Длина сигнала сохраняется у всех трансформаций, так что кадры модели выравниваются покадрово.

Проверенные альтернативы (имена — это ключи конфигов в `sweep_inference.py`):

Имя набора	Описание	Валидационный CER
basic	± 0.5 пт + полоса 5.5 кГц (3 варианта)	0.0223
wide	± 0.5 и ± 1.0 пт + полоса 4.5 / 5.5 / 6.5 кГц (7 вариантов)	0.0225
small	± 0.3 пт + полоса 5.5 кГц	0.0229
pitch_only	только сдвиг тона ± 0.5 / ± 1.0	0.0228
bandwidth_only	только полосы 4.5 / 5.5 / 6.5	0.0239

Умеренный пакет лучше крайностей: слишком широкий ТТА «размывает» сигнал.

8. Усреднение весов соседних эпох (SWA)

На финальных эпохах каждого цикла усредняли 2–4 соседних снимка весов. Эффект — около 1–3 % валидационного CER относительно лучшего одиночного чекпоинта:

Цикл	Лучший вариант SWA	Эффект
v2	SWA(эпохи 8, 9)	LB 4.440 → 4.034
С нуля	SWA(эпохи 16, 18, 19, 20)	гармоническое среднее 0.0205 → 0.0199
С реверб	SWA(эпохи 23, 25, 26)	валидация 0.0166 → 0.0152 (с ТТА)
Сид 43	эпоха 20 одиночно (SWA хуже)	кривая слишком крутая, усреднение «размывает»

Правило из опыта: SWA помогает, когда обучение вышло на плато; когда ошибка ещё активно падает — может даже вредить.

Что проверили и не взяли в финал

Штраф за вставку слова в лучевой декодер ($-\lambda \cdot \text{число_слов}$)

Идея — мешать декодеру «домысливать» лишние токены на шумных участках. Прогнали перебор $\lambda \in \{0, 0.5, 1.0, 1.5, 2.0, 3.0\}$ на модели с нуля + ТТА:

λ	Валидационный CER
0.0	0.0337
0.5	0.0347
1.0	0.0352
1.5	0.0358
2.0	0.0370
3.0	0.0401

Любой ненулевой штраф только ухудшает. Интерпретация: грамматический декодер уже достаточно жёсткий, дополнительный штраф начинает резать легитимные длинные числа (7+ слов).

Увеличение размера луча

Лучевой декодер с размерами луча 16, 32 и 64 даёт идентичный валидационный CER до четвёртого знака. При такой компактной грамматике 16 лучей покрывают всё пространство гипотез.

Широкий ТТА (7 вариантов)

См. таблицу выше: больше вариантов → больше шума → хуже.

Сабмит по неполному локальному **test**

В ранних сессиях пробовали отправить предсказания по неполной локальной тестовой выборке (не заметили, что недокачалось) — получили бессмысленный скор 84.7 из-за заглушек по отсутствующим файлам. Но это было все равно выше бейзлайна :О)

Что осознанно не делали

- Внешняя языковая модель. Грамматика уже встроена в декодер через конечный автомат, LM излишен.
- Архитектурные изменения (Conformer, внимание). Бюджет 5 млн параметров почти выбран, а разрыв в данных ещё не был закрыт — риск выше ожидаемой отдачи.
- Более широкая модель (encoder_dim 256 → 320). После получения 1.507 с крепким отрывом до ближайшего соперника ансамбль двух моделей с разными сидами оценили как более надёжный ход, чем масштабирование архитектуры.

Ход сессий и принятые решения

Единый критерий выбора во всех сессиях — валидационный CER и `harmonic_cer`.

Маппинг сессий на шаги из таблицы «Коротко»:

Сессия	Шаги «Коротко»
1	1
2	2–3
3	4
4	5
5	6

Сессия 1 — пакет аугментаций v2

Гипотеза. Главный разрыв — `tr3`, полоса, новые говорящие. Проверяем малоинвазивно: добавляем аугментации и балансировку, дообучаем одну эпоху от старой базы. LR = $1e-4$, без графика.

Что получили. Одна эпоха v2 дала 6.835 → 5.082. Гипотеза подтверждена. Продолжаем тот же рецепт, пока ошибка снижается.

Сессия 2 — дообучение до плато

Серия коротких дообучений по 2–3 эпохи с убывающим LR ($1.5e-4 \rightarrow 1e-4 \rightarrow 7e-5 \rightarrow 5e-5$), каждый шаг — сверка по валидации. Дошли до LB 4.034 через SWA(8, 9). Кривая валидации выполаживается.

Наблюдение. Весь прирост идёт от аугментаций, а не от длительности. Модель, обучавшаяся в ранние эпохи на «чистых» данных, не желает полностью адаптироваться к аугментациям через дообучение.

Сессия 3 — обучение с нуля (перелом)

Решение. Обучать с нуля со всеми аугментациями, 20 эпох, пик LR $1e-3$, косинусный график с прогревом 1.5 эпохи.

Результат. Валидация 0.0223, LB 2.362. Одна тренировка — снижение на 42 %. Главный прорыв стратегии.

Сессия 4 — реверберация

Гипотеза. Единственный оставшийся акустический фактор, который есть в валидации и нет в обучении, — эхо помещений. Добавляем реверберацию и дообучаем 6 эпох от лучшей модели сессии 3 (пик LR $2e-4$, косинусный график с прогревом 0.5 эпохи).

Результат. Валидация 0.0152, LB 1.507. Дополнительное подтверждение: spk_K и spk_H — именно те говорящие, для которых эхо было критично.

Сессия 5 — ансамбль

Гипотеза. Для устойчивости на приватной части лидерборда и дополнительного прироста — ансамбль двух моделей с разными сидами. Вторая модель обучается с нуля, реверберация включена с первой эпохи.

Результат. Одиночная модель сида 43 сама по себе дала CER 0.0128 (лучше финала сида 42). Ансамбль — 0.0115, LB 0.946.

Бюджет вычислений

Всё обучение шло на CPU ноутбука (MacBook, Apple Silicon, MPS на CTC-loss не поддерживается в torch 2.11, пришлось считать на CPU).

Цикл обучения	Эпохи	Время	Пик LR
v2 + дообучения до плато	1 + 2 + 3 + 3 + 3 = 12	~4 ч	$1e-4 \rightarrow 5e-5$
С нуля (сид 42)	20	~6 ч	$1e-3$
Дообучение с ревербом (сид 42)	6	~2 ч	$2e-4$
С нуля с ревербом (сид 43)	22	~9 ч	$1e-3$
Итого	60	~21 ч CPU	

Kaggle-кERNEL инференса (GPU): ~90 секунд на 2 582 тестовых примера для ансамбля (2 модели × 4 ТТА-прохода, плюс лучевой декодер на CPU).

Всего отправок на Kaggle в этой сессии — 7, растянуты на два дня из-за лимита 5 сабмитов в сутки.

Связь валидационного CER и LB

Для всех 7 сабмитов сессии:

Сабмит	Валидационный CER	LB	LB / CER
v2, эпоха 1	0.0535	5.082	95.0
v2-cont, эпоха 5	0.0472	4.618	97.8
v2-cont, эпоха 6	0.0455	4.440	97.6
SWA(8, 9)	0.0394	4.034	102.4
С нуля + SWA + ТТА	0.0223	2.362	105.9
С реверб + SWA + ТТА	0.0152	1.507	99.2
Ансамбль + ТТА	0.0115	0.946	82.3

Коэффициент держится в диапазоне 82–106 со средним около 97. Относительно стабильная линейная зависимость — валидация является хорошим прокси для теста.

Пример остаточной ошибки модели

Финальная модель по-прежнему допускает ошибки на трудных OOD-записях. Пример из валидации:

Поле	Значение
Говорящий	spk_1 (OOD)
Эталонное число	473 738
Словесный эталон	четыреста семьдесят три тысячи семьсот тридцать восемь
Предсказание (слова)	сто сорок шесть тысяч два
Предсказание (число)	146 002
CER	1.00

Из 7 эталонных слов модель эмитирует только 4, и они другие. Это не ошибка декодера — жадный и лучевой декодеры дают одинаковый результат — а акустическая ошибка: модель «слышит» другое число. Такие случаи характерны для тихих mp3-записей с сильной полосовой фильтрацией, где маркер «тысяч» теряется и модель додумывает короткую триплетную структуру. Дальнейшее снижение CER, вероятно, требует либо лучшего акустического представления, либо более жёстких OOD-аугментаций.

Что можно попробовать дальше

Идеи, которые не вошли в эту сессию, но можно было бы еще попробовать:

Ансамбль с большим разнообразием

- Третий и четвёртый сид. Каждая дополнительная модель даёт убывающий, но ненулевой вклад (обычно –3–10 % CER у 3-й модели, меньше у 4-й). Бюджет: ~9 ч CPU на модель.
- Диверсификация не только по сиду, но и по гиперпараметрам аугментаций. Разные rt60-диапазоны, разные наборы mp3-битрейтов, разный dropout. Идея — чтобы модели ошибались по-разному.
- Обучение одной из моделей с меньшим hop (128 вместо 160) — разная временная разрешающая способность.

Архитектурные изменения в бюджете 5 млн параметров

- Углубить энкодер. Один дополнительный Conv-слой со страйдом 1 между двумя существующими, с LayerNorm. Даёт больше рецептивного поля без снижения разрешения.
- Заменить последний BiGRU на небольшой блок Conformer-типа (multi-head attention + swish-conv). Хорошо работает для ASR на короткой речи, но съедает ~1 млн параметров — нужно ужимать остальное.
- Шире mel: 80 → 128 бинов. +0.2 млн параметров.
- Послойный LR. Снижать LR для свёрточного стека и оставлять большим для GRU. Часто ускоряет сходимость без потери качества.

Усложнить аугментации

- Реальные RIR из публичных свободных датасетов (MIT-IR, OpenAIR). Наш синтетический реверб — приближение; реальные импульсные отклики дают разнообразие помещений, которого нет в экспоненциальном шуме. Проверить, подпадает ли под правила использования публичных RIR-баз.
- Сжатие другими кодеками (Opus, AAC). Тест, возможно, содержит не только mp3.
- Vocal tract length perturbation (VTLP) — имитация разных длин голосового тракта, более физиологически обоснованная, чем простой сдвиг тона.
- SpecSwap / SpecCutout — усложнённые варианты SpecAugment: swap меняет местами два случайных отрезка спектрограммы, cutout вырезает прямоугольную область; обе операции дают более богатые искажения, чем простые маски нулями.
- Микс во временной области между двумя записями одного говорящего. Необычная, но работающая схема для коротких классификаций.

Улучшения декодера

- Обучаемый штраф за вставку токена. Натренировать маленькую MLP на валидации, которая предсказывает оптимальный штраф в зависимости от контекста (уровень шума, длина клипа, соседние токены). Вместо глобального λ — адаптивный.
- Вторичный проход по топ-K гипотезам с более тяжёлым ре-скорингом (например, повторно прогнать лучшие 5 через более крупную модель). Классический подход в ASR.
- Конфидентное голосование: если разные ТТА-варианты дают одно число — высокая уверенность; если расходятся — прогнать отдельную более «дорогую» расшифровку.

Более точное обучение

- SAM / Sharpness-Aware Minimization вместо AdamW. Даёт более плоский минимум.
- EMA (Exponential Moving Average) весов. Дешевле SWA.
- Более длинный график обучения. 30–40 эпох вместо 20, косинусный график с более пологим хвостом. Сильные аугментации требуют больше времени, чем мы дали.

Диагностика остаточных ошибок

- Кластеризация ошибочных примеров по акустическим признакам. Возможно, найдётся отдельный класс (например, «женские OOD в тихих помещениях»), под который можно прицельно добавить аугментаций.
- Анализ временного выравнивания CTC для ошибочных примеров — понять, на какой части аудио модель «теряется».

Самый большой ожидаемый выигрыш — от расширения ансамбля до 3–4 моделей и/или от тренировки с реальными RIR. Оба требуют заметного дополнительного вычислительного бюджета, но хорошо предсказуемы по результату.

Итоговый пайплайн инференса (Kaggle-кernels)

1. Загрузка обоих чекпоинтов

```
best.pt          = сид 42, reverb + SWA(23, 25, 26)
best_seed43.pt   = сид 43, эпоха 20 с нуля + реверб
```

2. Для каждого батча:

Для каждой модели:

```
а. прямой проход                → log_softmax_0
б. прямой проход + pitch +0.5 пт → log_softmax_1
в. прямой проход + pitch -0.5 пт → log_softmax_2
г. прямой проход + полоса 5.5 кГц → log_softmax_3
усреднение                      = model_avg
ensemble = (model_avg_42 + model_avg_43) / 2
words    = grammar_beam_decode(ensemble, beam = 16)
number   = детерминированный_разбор_слов_в_число(words)
```

3. submission.csv

Структура проекта

src/asr_numbers/

audio.py	– загрузка, ресэмплинг через scipy
augment.py	– mp3 / полоса / тон / реверберация, всё на numpy
dataset.py	– датасет + WeightedRandomSampler для балансировки
decoder.py	– жадный + CTC-prefix-beam с грамматикой
features.py	– самодостаточный log-mel + SpecAugment с относительными масками
metrics.py	– CER, CER по говорящим, CER по доменам
model.py	– ConvGRUCTCModel, ~3.5 млн параметров
text.py	– число ↔ слова (мужской / женский / нейтральный)

tta.py – TTA через усреднение log_softmax
vocab.py – словарь слов (42 слова + blank)

scripts/
train.py – цикл обучения + косинусный LR + возможность продолжить с чекпоинта
eval_dev.py – одна модель, жадный / beam / TTA
eval_ensemble.py – несколько моделей + TTA + beam
analyze_dev_errors.py – разбор ошибок по говорящим
average_checkpoints.py – SWA
sweep_inference.py – перебор beam × TTA
submit_from_kernel.sh – скачать результат работы ядра и отправить на Kaggle

kaggle_assets/
weights_dataset/ – датасет с обоими чекпоинтами
full_test_kernel/ – самодостаточный ядро инференса с ансамблем

История сабмитов

Все успешные отправки на публичную часть лидерборда, по возрастанию даты:

#	Дата (UTC)	Описание	Публичный CER
1	2026-04-12 06:41	baseline_quick_full_test_v1 — первая рабочая отправка baseline	27.122
2	2026-04-12 07:09	baseline_quick_full_test_v2_epoch12 — dev 0.1182	12.061
3	2026-04-12 07:59	baseline_quick_full_test_v3_epoch1335 — dev 0.0738 (конец прошлой сессии)	6.135
4	2026-04-21 09:56	aug_v2 epoch 1 — codec/bandwidth/pitch/SpecAugment + балансировка, dev 0.0535	5.082
5	2026-04-21 10:24	aug_v2_cont epoch 5 — dev 0.0472	4.618
6	2026-04-21 10:29	aug_v2_cont epoch 6 — dev 0.0455	4.440
7	2026-04-21 11:05	SWA(epoch 8, 9) с beam=16, dev 0.0394	4.034
8	2026-04-22 02:44	scratch + SWA(16, 18, 19, 20) + TTA + beam16, dev 0.0223	2.362
9	2026-04-22 06:07	reverb + SWA(23, 25, 26) + TTA + beam16, dev 0.0152	1.507
10	2026-04-22 17:00	ensemble(сид 42 reverb SWA + сид 43 e20) + TTA + beam16, dev 0.0115 — финал	0.946

Все чекпоинты отбирались по локальному валидационному CER, а не по значениям лидерборда.

Главные уроки

1. Диагностика расхождения обучения и теста сильнее архитектурных трюков, когда расхождение структурно-акустическое. Все четыре главные аугментации (mp3, полоса, тон, реверберация) — прямой

ответ на наблюдаемый сдвиг.

2. Обучение с нуля со всем набором аугментаций важнее длительного дообучения. Привыкание к аугментациям «запекается» в ранние слои и через дообучение передаётся плохо.
3. Ансамбль моделей с разными сидами — самый надёжный способ добиться результат. Удвоили вычисления, получили −24 % валидационного CER почти без риска.
4. Грамматический декодер сильнее размера луча. При жёсткой грамматике 16 лучей хватает с запасом, дальше — только лишние вычисления.
5. Все решения — по локальной валидации. Отношение LB к валидации оставалось стабильным, никакой подгонки под LB.
6. Сохраняйте снимок весов после каждой эпохи. SWA требует доступа к промежуточным чекпоинтам — потерянный шаг потом не восстановить.